PriorScope 비교 입력

안내

- 이 문서는 투고할 논문(내 논문)과 기존 논문 1편을 비교하기 위한 입력이다.
- 내 논문의 핵심 기술 요소는 M1…Mn, 기존 논문의 핵심 기술 요소는 P1…Pn이다.
- 내 논문의 실험 결과는 R-M1…, 기존 논문의 실험 결과는 R-P1…이다.
- 각 요소는 '[섹션번호] 원문 표현 | 한국어 설명' 형식이고, 각 실험 결과는 '데이터셋 | 방법 이름 | 지표 | 수치 | 방향 | 위치' 형식이다. 방법 이름은 양쪽 논문이 당연히 다르므로 조건 판단에 쓰지 않는다.
- 반드시 이 문서에 적힌 번호만 사용하고, 새 번호를 만들지 않는다.
- element_mapping은 M 요소마다 한 줄씩 'M2 ↔ P4,P5 | 유사 | M[3.1] / P[2.3] | 설명' 형식으로 쓴다. 대응하는 P가 없으면 'M3 ↔ - | 없음 | 검토 범위 | 설명'으로 쓴다.
- 판정은 일치, 유사, 없음, 확인필요 중 하나다. 같은 기술을 다른 용어나 다른 언어(국문/영문)로 쓴 경우도 대응으로 본다. 대응을 확신하지 못하면 '없음'이 아니라 '확인필요'로 적는다.
- result_pairs는 데이터셋과 지표가 같은 쌍만 'R-M1 ~ R-P2 | 동일 조건 | 설명' 형식으로 쓴다. 지표 표기가 달라도(예: Top-1과 top-1 accuracy, R@1과 Recall@1) 같은 지표면 쌍으로 본다. 2열에는 반드시 '동일 조건' 또는 '조건 다름'을 적는다. zero-shot과 fine-tuning처럼 학습 방식이 다르거나 학습 데이터·평가 분할이 다르면 '조건 다름'이다. 확신하지 못하면 '조건 다름'으로 적는다.

내 논문 (My Paper)

Title

Towards Open-Vocabulary Audio-Visual Event Localization

Language

en

Problem

• Most research in this field assumes a closed-set setting, which restricts these models' ability to handle test data containing event categories absent (unseen) during training.

• Recently, a few studies have explored AVEL in an open-set setting, enabling the recognition of unseen events as "unknown", but without providing category-specific semantics.

• OV-AVEL requires localizing audio-visual events and predicting explicit categories for both seen and unseen test data at inference.

Core Techniques (M)

M1. [1] the OV-AVEBench dataset | 보지 못한 클래스까지 포함하는 개방어휘 AVEL용 세그먼트 단위 수동 주석 데이터셋을 구축함

M2. [1] three evaluation metrics | 정확도 외에 세그먼트 수준 및 이벤트 수준 F1을 포함한 평가 지표를 정립함

M3. [1] the unified multimodal space from the pretrained ImageBind model | 사전학습된 ImageBind의 공통 멀티모달 임베딩 공간에서 오디오·비주얼·텍스트 특징을 추출함

M4. [1] The training-free baseline then determines predictions by comparing the consistency of audio-text and visual-text feature similarities | 오디오-텍스트와 비주얼-텍스트 유사도의 일치성으로 학습 없이 이벤트를 예측함

M5. [1] The fine-tuning baseline incorporates lightweight temporal layers to encode temporal relations within the audio and visual modalities | 경량 temporal layer를 추가해 오디오·비주얼 내부의 시간 관계를 인코딩함

M6. [3.2] the temporal layers are implemented as a stack of L standard Transformer [41] blocks | temporal layer를 표준 Transformer 블록 스택으로 구현함

M7. [3.2] we generate the final audio-visual event probability Save by fusing them as follows | 오디오/비주얼 확률을 결합해 최종 오디오-비주얼 이벤트 확률을 생성함

Contributions

• [3] We propose the Open-Vocabulary Audio-Visual Event Localization (OV-AVEL) task, aiming to localize both seen and unseen audio-visual events in test videos.

• [3] To facilitate this new task, we construct the OV-AVEBench dataset, which includes segment-level manual event annotations.

• [3] Besides, we establish standard evaluation metrics that encompass typical accuracy, as well as segment-level and event-level Fl-scores.

• [3] We present two simple baselines: one adopting a training-free paradigm, which can be upgraded through further fine-tuning on available training data.

Experiment Results (R-M)

R-M1. OV-AVEBench | Training-free (our) | Avg. | 46.6 | ↑ | [Table 2]

R-M2. OV-AVEBench | Fine-tuning (our) | Avg. | 57.8 | ↑ | [Table 2]

R-M3. OV-AVEBench | Fine-tuning (our), seen | Avg. | 62.9 | ↑ | [Table 2]

R-M4. OV-AVEBench | Fine-tuning (our), unseen | Avg. | 55.8 | ↑ | [Table 2]

R-M5. OV-AVEBench | Fine-tuning (our), with other | Avg. | 57.8 | ↑ | [Table 3]

R-M6. OV-AVEBench | Fine-tuning (our), Sqrt (Eq. 2) | Avg. | 57.8 | ↑ | [Table 4]

R-M7. OV-AVEBench | Fine-tuning (our), Temporal layer | Avg. | 57.8 | ↑ | [Table 5]

R-M8. OV-AVEBench | Fine-tuning (our), 100% training data | Avg. | 57.8 | ↑ | [Table 6]

R-M9. AVE | fine-tuning (our), zero-shot | Acc. | 61.9 | ↑ | [Table All]

기존 논문 (Prior Paper)

Title

IMAGEBIND: One Embedding Space To Bind Them All

Citation

Girdhar et al., arXiv, 2023

Problem

• Learning a true joint embedding across many modalities is infeasible with existing approaches because they require large quantities of multimodal data where all modalities and combinations co-occur with the same images.

• Existing methods typically align only a single pair or a few visual modality pairs, so the final embeddings are limited to the modality pairs used for training and do not transfer directly across other modality pairs.

• Unlocking zero-shot classification for non-image modalities usually requires explicit paired text supervision for each modality.

Core Techniques (P)

P1. [3.2] IMAGEBIND uses pairs of modalities (I,M), where I represents images and M is another modality, to learn a single joint embedding. | 이미지를 공통 축으로 사용해 각 모달리티를 하나의 공동

임베딩 공간에 정렬하는 학습 절차

P2. [3.2] we encode them into normalized embeddings: qi = f(Ii) and ki = g(Mi) where f,g are deep networks. | 이미지와 다른 모달리티를 각각 심층 인코더로 정규화된 임베딩으로 인코딩하는 구조

P3. [3.2] are optimized using an InfoNCE [54] loss | 이미지-모달리티 쌍 정렬을 위해 InfoNCE 대조학습 손실을 사용하는 학습 기법

P4. [3.2] we use a symmetric loss LI,M + LM,I. | 양방향 정렬을 위해 대칭 손실을 함께 사용하는 학습 방식

P5. [3.2] IMAGEBIND uses modalities paired with images, i.e., pairs of the form (I,M) to align each the embeddings from each modality M to those from images. | 모든 모달리티를 이미지와의 쌍으로만 학습해 이미지 임베딩에 정렬하는 바인딩 전략

P6. [3.2] We observe an emer- gent behavior in the embedding space that aligns two pairs of modalities (M1, M2) even though we only train using the pairs (I,M1) and (I,M2). | 이미지와 각각만 정렬했는데도 보지 않은 모달리티 쌍 사이 정렬이 발생하는 emergent alignment 메커니즘

P7. [3.3] We use a Transformer architec- ture [73] for all the modality encoders. | 전 모달리티 인코더를 Transformer 계열로 통일한 아키텍처 설계

P8. [3.3] We add a modality- specific linear projection head on each encoder to obtain a fixed size d dimensional embedding | 각 모달리티 인코더 뒤에 선형 프로젝션 헤드를 붙여 고정 차원 임베딩으로 투영하는 모듈

Limitations

- [6] Our embeddings are trained without a specific downstream task, and thus lag the performance of specialist models.
- [6] Our model is a research prototype and cannot be readily used for real world applications (Appendix F).
- [F] joint embedding may also create unintentional associations.
- [F] IMAGEBIND leverages the image-text embeddings learned by a pretrained model on large web-based data which has biases as documented in different studies [60].
- [F] These joint embeddings are thus limited to the concepts present in the datasets.

Experiment Results (R-P)

R-P1. IN1K | IMAGEBIND | top-1 accuracy | 77.7 | ↑ | [Table 2]

R-P2. P365 | IMAGEBIND | top-1 accuracy | 45.4 | ↑ | [Table 2]

R-P3. K400 | IMAGEBIND | top-1 accuracy | 50.0 | ↑ | [Table 2]

R-P4. MSR-VTT | IMAGEBIND | Recall@1 | 36.1 | ↑ | [Table 2]

R-P5. NYU-D | IMAGEBIND | top-1 accuracy | 54.0 | ↑ | [Table 2]

R-P6. SUN-D | IMAGEBIND | top-1 accuracy | 35.1 | ↑ | [Table 2]

R-P7. AS-A | IMAGEBIND | mAP | 17.6 | ↑ | [Table 2]

R-P8. VGGS | IMAGEBIND | top-1 accuracy | 27.8 | ↑ | [Table 2]

R-P9. ESC | IMAGEBIND | top-1 accuracy | 66.9 | ↑ | [Table 2]

R-P10. LLVIP | IMAGEBIND | top-1 accuracy | 63.4 | ↑ | [Table 2]

R-P11. Ego4D | IMAGEBIND | top-1 accuracy | 25.0 | ↑ | [Table 2]

R-P12. Clotho | IMAGEBIND | R@1 | 6.0 | ↑ | [Table 3]

R-P13. Clotho | IMAGEBIND | R@10 | 28.4 | ↑ | [Table 3]

R-P14. AudioCaps | IMAGEBIND | R@1 | 9.3 | ↑ | [Table 3]

R-P15. AudioCaps | IMAGEBIND | R@10 | 42.3 | ↑ | [Table 3]

R-P16. ESC | IMAGEBIND | Top-1 | 66.9 | ↑ | [Table 3]

R-P17. MSR-VTT | IMAGEBIND, A | R@1 | 6.8 | ↑ | [Table 4]

R-P18. MSR-VTT | IMAGEBIND, A | R@5 | 18.5 | ↑ | [Table 4]

R-P19. MSR-VTT | IMAGEBIND, A | R@10 | 27.2 | ↑ | [Table 4]

R-P20. MSR-VTT | IMAGEBIND, A+V | R@1 | 36.8 | ↑ | [Table 4]

R-P21. MSR-VTT | IMAGEBIND, A+V | R@5 | 61.8 | ↑ | [Table 4]

R-P22. MSR-VTT | IMAGEBIND, A+V | R@10 | 70.0 | ↑ | [Table 4]